Mini Project 01 - IMDB web scraping

```
url <- "https://www.imdb.com/search/title/?groups=top_100&sort=user_rating,desc"</pre>
```

```
print(url)
```

[1] "https://www.imdb.com/search/title/?groups=top_100&sort=user_rating,desc"

```
# read html
imdb <- read_html(url)</pre>
imdb
{html_document}
<html xmlns:og="http://ogp.me/ns#" xmlns:fb="http://www.facebook.com/2008/fbml"</pre>
[1] <head>\n<meta http-equiv="Content-Type" content="text/html; charset=UTF-8 .
[2] <body id="styleguide-v2" class="fixed">\n
                                                                     <img height="1" widt .</pre>
# movie title
titles <- imdb %>%
     html_nodes("h3.lister-item-header") %>%
     html_text2()
titles[1:10]
'1. The Shawshank Redemption (1994)' · '2. The Godfather (1972)' · '3. The Dark Knight (2008)' ·
'4. The Lord of the Rings: The Return of the King (2003)' · '5. Schindler\'s List (1993)' ·
'6. The Godfather Part II (1974)' · '7. 12 Angry Men (1957)' · '8. Pulp Fiction (1994)' · '9. Inception (2010)' ·
'10. The Lord of the Rings: The Two Towers (2002)'
# rating
ratings <- imdb %>%
     html_nodes("div.ratings-imdb-rating") %>%
     html_text2() %>%
     as.numeric()
```

```
ratings[1:10]
```

```
num_votes <- imdb %>%
  html_nodes("p.sort-num_votes-visible") %>%
  html_text2()
```

```
# build a dataset

df <- data.frame(
    title = titles,
    rating = ratings,
    num_vote = num_votes
)

head(df)</pre>
```

A data.frame: 6×3

	title	rating	num_vote
	<chr></chr>	<dbl></dbl>	<chr></chr>
1	1. The Shawshank Redemption (1994)	9.3	Votes: 2,667,799 Gross: \$28.34M Top 250: #1
2	2. The Godfather (1972)	9.2	Votes: 1,848,783 Gross: \$134.97M Top 250: #2
3	3. The Dark Knight (2008)	9.0	Votes: 2,640,693 Gross: \$534.86M Top 250: #3
4	4. The Lord of the Rings: The Return of the King (2003)	9.0	Votes: 1,838,957 Gross: \$377.85M Top 250: #7
5	5. Schindler's List (1993)	9.0	Votes: 1,350,739 Gross: \$96.90M Top 250: #6
6	6. The Godfather Part II (1974)	9.0	Votes: 1,266,090 Gross: \$57.30M Top 250: #4

Mini Project 02 - Spec Phone Database

```
url <- "https://specphone.com/Samsung-Galaxy-A04.html"
specphone <- read_html(url)</pre>
```

```
att <- specphone %>%
   html_nodes("div.topic") %>%
   html_text2()

value <- specphone %>%
   html_nodes("div.detail") %>%
   html_text2()
```

```
data.frame(attribute = att, value = value)
```

A data.frame: 31 × 2

attribute	A data.frame: 31 × 2
<chr></chr>	<chr></chr>
วันเปิดตัว	ตุลาคม 2565
วันวางจำหน่าย	ยังไม่วางจำหน่าย
ขนาด	164.40 x 76.30 x 9.10 มม.
น้ำหนัก	192 กรัม
วัสดุ	Glass front, plastic back, plastic frame
SIM	รองรับ 2 ซิมการ์ด (nano sim, nano sim)
Technology	HSPA 42.2/5.76 Mbps, LTE-A
2G	850/900/1800/1900
3G	850/900/1900/2100
4G	850/900/1900/2100/2600
5G	-
ความเร็ว	HSPA 42.2/5.76 Mbps, LTE-A
ประเภท	PLS LCD
ขนาดหน้าจอ	6.50 นิ้ว
ความละเอียด	720 x 1600 pixels
ระบบปฏิบัติการ	Android 12
ชิปประมวลผล	Spreadtrum Unisoc SC9863A 1.6 GHz
ชิปกราฟิก	PowerVR GE8322
หน่วยความจำ	3 GB
ความจุ	32 GB
Memory Card	microSD (1)
กล้องหลัก	ตัวที่ 1: 50 MP, f/1.8, (wide), AF ตัวที่ 2: 2 MP, f/2.4, (depth)
ความละเอียดวีดีโอ	1080p@30fps
กล้องหน้า	ตัวที่ 1: 5 MP, f/2.2
Bluetooth	5.0, A2DP, LE
Wi-Fi	802.11 a/b/g/n/ac, dual-b
USB	Type-C
GPS	GLONASS, GALILEO, BDS
NFC	ไม่รองรับ
ความจุ	5,000 mAh
ประเภท	Non-removable Li-Po Batt

```
# all samsung smartphone
```

samsung <- read_html("https://specphone.com/brand/Samsung")</pre>

```
# link to all samsung smartphone
links <- samsung %>%
  html_nodes("li.mobile-brand-item a") %>%
  html_attr("href")
```

```
full_links <- paste0("https://specphone.com", links)</pre>
```

```
result <- data.frame()
for (link in full_links[1:10]){
    ss_topic <- link %>%
        read_html() %>%
        html_nodes("div.topic") %>%
        html_text2()
    ss_detail <- link %>%
        read_html() %>%
        html_nodes("div.detail") %>%
        html_text2()
    tmp <- data.frame(attribute = ss_topic,</pre>
                       value = ss_detail)
    result <- bind_rows(result, tmp)</pre>
    print("Progress...")
}
print(result)
```

```
[1] "Progress..."
2 วันเปิดตัว
2 วันวางจำหน่าย
```

```
      3
      ขนาด

      4
      น้ำหนัก

      5
      วัสดุ

      6
      SIM

      7
      Technology

      8
      2G
```

print(head(result))

```
attribute
                                                        value
      วันเปิดตัว
                                                มิถุนายน 2565
1
2 วันวางจำหน่าย
                                             ยังไม่วางจำหน่าย
                                 165.40 x 76.90 x 8.40 มม.
3
          ขนาด
4
         น้ำหนัก
                                                     192 กรัม
5
           วัสดุ Glass front, plastic back, plastic frame
           SIM
                     รองรับ 2 ซิมการ์ด (nano sim, nano sim)
```

```
# write csv
write_csv(result, "result_ss_phone.csv")
```